

知网个人查重服务报告单(全文标明引文)

报告编号:BC202504232304125152038233

检测时间:2025-04-23 23:04:12

篇名: 社交媒体多模态数据的统计挖掘与抑郁倾向预测研究

作者: 孙浩男;张晰朗;陈锦涛

所在单位: 辽宁科技大学

检测类型: 职称评审

比对截止日期: 2025-04-22

检测结果

去除本人文献复制比: 0.4% 去除引用文献复制比: 0.4% 总文字复制比: 0.4%

单篇最大文字复制比: 0.2% (基于深度学习的目标检测算法研究)

重复字符数: [77] 单篇最大重复字符数: [46] 总字符数: [18621]

0% (0) 0% (0) 社交媒体多模态数据的统计挖掘与抑郁倾向预测研究_第1部分 (总9740字)
0.9% (77) 0.9% (77) 社交媒体多模态数据的统计挖掘与抑郁倾向预测研究_第2部分 (总8881字)

(注释: 无问题部分 文字复制部分 引用部分)

1. 社交媒体多模态数据的统计挖掘与抑郁倾向预测研究_第1部分 总字符数: 9740

相似文献列表

去除本人文献复制比: 0% (0) 去除引用文献复制比: 0% (0) 文字复制比: 0% (0)

原文内容

作品编号: TJJM20250310037664
2025年(第十一届)全国大学生统计建模大赛
参赛作品
参赛学校: 辽宁科技大学
论文题目: 社交媒体多模态数据的统计挖掘与抑郁倾向预测研究
参赛队员: 孙浩男张晰朗陈锦涛
指导老师: 吴佳美

社交媒体多模态数据的统计挖掘与抑郁倾向预测研究

摘要

本研究聚焦于社交媒体多模态数据的统计挖掘与抑郁倾向预测,通过整合文本、时间、表情和社交数值四类模态数据,构建了一种基于注意力机制的多模态融合模型。研究首先对社交媒体数据进行清洗与标注,采用哈希去重、多重插补等技术确保数据质量,并通过VADER情感分析、EmojiSentiment词典及时间节律特征提取等方法,构建了涵盖语义、情感、行为节律和社交互动的多维特征体系。模型采用双向LSTM处理文本模态,全连接网络提取时间和社交特征,并引入多头注意力机制实现动态加权融合。实验结果表明,模型在测试集上准确率达92.2%,AUC值为0.975,显著优于单模态基线模型。SHAP值分析显示,夜间发帖比例、消极表情占比及社交互动减少等特征对抑郁预测贡献显著,验证了模型的可解释性。本研究为抑郁早期预警提供了数据驱动的新方法,同时为社交媒体平台实现实时心理健康监测提供了技术支撑。

关键词: 社交媒体;多模态数据;抑郁预测;注意力机制;统计挖掘

Abstract

This study focuses on statistical mining of multimodal social media data for depression tendency prediction, integrating four types of modalities: text, temporal patterns, emojis, and social interaction metrics. A novel attention-based multimodal fusion model is proposed, leveraging Bidirectional LSTM for text processing, fully connected networks for temporal and social feature extraction, and multi-head attention mechanisms for dynamic feature weighting. The dataset was rigorously preprocessed using hash-based deduplication, multiple imputation for missing values, and anonymization techniques. Feature engineering

incorporated VADER sentiment analysis, EmojiSentiment lexicon classification, and temporal rhythm quantification. Experimental results demonstrated superior performance with 92.2% accuracy and 0.975 AUC, significantly outperforming unimodal baselines. SHAP value analysis revealed key predictive features including nocturnal posting frequency, negative emoji usage, and reduced social engagement, aligning with established psychological theories of depression. The model provides a data-driven approach for early depression detection while offering interpretable decision-making insights. Its implementation framework enables real-time mental health monitoring through social media platforms, bridging the gap between digital behavior analysis and clinical applications.

Keywords: social media; multimodal data; depression prediction; attention mechanism; statistical mining

目录

摘要.....1

Abstract.....2

表格与插图清单.....5

一、 引言.....6

（一）研究背景.....6

（二）研究目的.....7

1. 多模态数据中的抑郁相关特征挖掘.....7

2. 多模态融合预测模型的构建与优化.....8

3. 模型效能验证与临床应用转化.....8

4. 方法论拓展与领域知识贡献.....9

二、 数据采集与清洗.....10

（一）数据来源与标注.....10

1. 去重技术.....10

2. 缺失值处理.....11

3. 敏感信息脱敏.....11

4. 标注质量控制.....11

（二）数据集中的数据类型展示.....11

（三）多模态数据构成.....12

三、 模型预处理.....12

（一）文本模态处理.....12

（二）时间模态处理.....17

（三）表情模态处理.....17

（四）社交数值模态处理.....18

社交行为组合特征：.....18

四、 多模型融合模型.....19

（一）模型整体架构设计.....19

（二）模态特征提取模块.....20

（三）多模态融合模块.....22

（四）分类预测模块.....23

五、 模型检验.....23

六、 总结与建议.....29

（一）总结.....29

（二）建议.....31

参考文献.....32

致谢.....34

表格与插图清单

表1. 多模态数据演示示例

图1. VADER 情感得分分布图

图2. VADER 情感分析模型图

图3. 矩阵对比模型图

图4. 文本分析模型性能对比图

图5. 文本分析模型ROC对比图

图6. 多模态融合模型整体架构流程图

图7. 模型混淆矩阵图

图8. 模型ROC曲线图

图9. 模型训练与验证损失曲线图

图10. 模型中Top 20重要特征图

图11. SHAP值散点图

社交媒体多模态数据的统计挖掘与抑郁倾向预测研究

一、 引言

（一）研究背景

随着社交媒体成为全球数亿用户日常交流的核心平台，其承载的多模态数据（文本、图像、表情、时间戳、社交互动记录等）已成为窥探用户心理状态的重要窗口。据 Statista 数据显示，截至 2024 年，全球社交媒体用户日均使用时长突破 2.8 小时，用户每分钟产生超 50 万条推文、10 万张图片及数百万次点赞 / 转发行为。这些数据不仅记录着个体的社交轨迹，更隐含着情绪波动、生活模式乃至心理健康状态的蛛丝马迹。抑郁作为全球范围内最常见的精神疾病之一，世界卫生组织（WHO）数据表明，全球约有 3.8 亿人受其影响，但早期识别率不足 50%，传统基于量表或临床访谈的诊断方式存在滞后性和主观性。因此，利用社交媒体多模态数据构建实时、非侵入性的抑郁倾向预测模型，成为心理学与数据科学交叉领域的前沿方向。

从技术层面看，单一模态数据（如纯文本或纯社交数值）的分析难以全面捕捉抑郁的复杂特征。例如，文本中的负性词汇（如“绝望”“疲惫”）虽能反映情绪状态，但用户的发帖时间（如凌晨高频发帖）、表情使用模式（如频繁使用 😞、😓）及社交活跃度（如关注者骤减）等特征往往蕴含互补信息。多模态融合通过整合不同维度的数据，能够更立体地刻画用户的心理画像。然而，现有研究多局限于单模态或简单特征拼接，缺乏对模态间交互关系的深度建模，导致预测准确率普遍低于 75%。

- 在此背景下，本研究聚焦于社交媒体多模态数据的统计挖掘与智能预测，旨在通过以下创新突破现有局限：
1. 多维度特征工程：结合文本语义、时间节律、表情情感及社交行为的跨模态关联分析，挖掘抑郁相关的统计规律（如夜间负性文本爆发性增长、社交互动骤降等）；
 2. 注意力机制驱动的融合模型：利用深度学习自动学习不同模态的权重分配，提升关键特征（如负性文本、异常时间模式）的贡献度；
 3. 临床价值导向：通过与临床标注数据的对比，验证模型在抑郁早期预警中的实际效能，为基层医疗和心理健康监测提供可落地的技术工具。

本研究的开展不仅有助于突破传统抑郁诊断的瓶颈，更有望为“数字心理健康”（Digital Mental Health）领域提供兼具创新性与实用性的方法论参考，推动人工智能在精神卫生领域的应用范式变革。

（二）研究目的

本研究以社交媒体多模态数据为核心分析对象，旨在通过统计挖掘与机器学习的深度结合，构建高精度、可解释的抑郁倾向预测模型，具体目标如下：

1. 多模态数据中的抑郁相关特征挖掘
- 本研究旨在通过多模态数据的跨维度分析，系统挖掘与抑郁倾向显著相关的特征体系，具体涵盖单模态统计描述、跨模态关联分析及特征交互建模三层次目标。首先，通过描述性统计（如均值、标准差、频率分布）刻画抑郁组与非抑郁组在文本、时间、表情、社交数值模态的基础差异，例如量化抑郁用户文本情感得分的均值显著低于非抑郁组（独立样本 t 检验， $p < 0.001$ ），验证夜间发帖比例与抑郁标签的正相关性（卡方检验， $p < 0.01$ ），并统计消极表情占比在两组间的分布差异。其次，运用皮尔逊相关系数、卡方检验等方法，识别跨模态关联特征，如文本情感极性与社交活跃度（关注者数、转发数）的负相关性，验证“负性文本 + 低社交互动”组合对抑郁的协同影响效应。同时，借助 SHAP 值、LIME 等机器学习工具评估特征重要性，量化各模态对预测结果的贡献度排序，例如发现夜间发帖频率、消极表情占比、文本情感极性的 SHAP 值排名靠前，揭示时间节律与情感表达的关键作用。
- 在特征交互建模层面，研究将构建多维度特征体系，探索不同模态特征的协同模式。例如，通过逻辑回归交互项分析，检验“负性文本（情感得分 ≤ -0.3 ）与低社交活跃度（转发数 \leq 中位数）”的组合是否使抑郁风险提升 1.5 倍以上；利用决策树模型可视化特征分割点，识别“夜间发帖比例 $\geq 30\%$ 且消极表情占比 $\geq 50\%$ ”的典型抑郁特征组合。此外，研究将采用主成分分析（PCA）或因因子分析降维，提炼核心特征维度（如“社交退缩因子”“夜间活动因子”），简化模型输入空间的同时保留关键信息。

通过上述分析，研究旨在突破单模态分析的局限性，构建涵盖“语义 - 时间 - 情感 - 社交”的四维特征网络，为多模态融合模型提供具有临床解释性的特征输入。这一过程不仅可识别如“凌晨高频发帖 + 消极词汇密集 + 社交互动骤降”的复合风险模式，更能为抑郁的病理机制研究提供数据驱动证据，例如验证“昼夜节律紊乱 - 负性认知 - 社交隔离”的恶性循环路径，丰富数字心理健康领域对抑郁多维度表型的认知。

2. 多模态融合预测模型的构建与优化
- 设计基于注意力机制的深度学习框架，实现文本（LSTM/Transformer）、时间（全连接层）、表情（分类特征）、社交数值（标准化数值）的动态加权融合，模型架构创新体现在通过注意力机制动态抑制冗余特征（如非抑郁用户的正常社交数值），强化关键特征贡献（如夜间发帖比例、负性文本情感得分），公式化表达为：公式（1）
- 其中，为模态权重（通过注意力机制学习），为各模态特征提取函数。再引入正则化（L2/L1）、Dropout 和 K 折交叉验证，提升模型泛化能力，避免过拟合进行算法优化。与单模态模型（如仅文本的 LSTM、仅数值的随机森林）及传统融合方法（如简单拼接）对比，验证多模态融合的性能优势。

3. 模型效能验证与临床应用转化
- 模型效能验证聚焦于量化评估、可解释性分析与场景适配三方面，以确保模型的临床实用价值。在量化评估中，研究采用准确率、召回率、AUC-ROC 等多指标体系，对测试集数据进行全面验证，目标设定为准确率 $\geq 80\%$ 、AUC-ROC ≥ 0.85 ，通过对比单模态模型和传统融合方法，突出多模态融合模型在综合性能上的优势。可解释性分析通过 SHAP 值量化各特征贡献度，例如文本情感极性、夜间发帖比例等关键特征的 SHAP 值排序靠前，结合注意力权重热力图可视化，清晰呈现模型对“负性文本 + 异常时间模式”等组合特征的决策逻辑，增强临床医生对模型预测结果的信任度。在场景适配层面，针对社交媒体数据的实时性特点，优化模型推理速度，使其满足动态监测需求，并探索其在抑郁高危人群筛查中的应用潜力，例如通过 API 接口嵌入社交平台后台，实现用户行为数据的实时分析与风险预警，为心理咨询机构提供早期干预的量化依据。此外，研究结合临床标注数据，验证模型在不同年龄、性别群体中的泛化能力，确保其在基层医疗场景中的适用性，例如在社区心理健康筛查中，模型可通过分析用户发帖内容的情感波动、夜间活动频率及社交互动模式，自动识别潜在抑郁倾向个体，降低传统量表筛查的人力成本与主观性偏差。通过上述验证与优化，模型不仅实现了技术层面的性能突破，更贴近真实临床需求，为数字心理健康监测提供了可落地的技术工具。

4. 方法论拓展与领域知识贡献

本研究通过构建“数据采集 - 统计挖掘 - 模型构建 - 临床验证”的跨学科研究框架，为心理学、计算机科学与临床医学的交叉研究提供了可复用的方法论范式。在数据层面，首次整合社交媒体文本语义、时间节律、表情情感及社交数值四类模态数据，突破传统单模态研究的局限性，建立了覆盖用户心理状态、行为模式与社交生态的多维分析体系，为数字心理健康领域提供了标准化的数据采集与标注流程参考。在方法层面，提出基于注意力机制的多模态动态融合模型，通过深度学习自动学习模态权重，解决了传统特征拼接方法无法捕捉模态间非线性交互的问题，该架构可泛化至焦虑症筛查、自杀风险预测等其他精神健康领域。通过大规模数据分析，研究发现“负性文本 + 异常时间节律 + 社交退缩”的多模态特征组合是抑郁倾向的典型表现模式，这些发现深化了对抑郁“数字表型”的认知，补充了传统心理学理论中关于“环境 - 行为 - 情绪”交互机制的实证证据。此外，研究验证了社交媒体数据在抑郁早期预警中的临床价值，为基层医疗场景提供了可落地的技术工具，有望通过嵌入社交平台 API 实现实时心理监测，推动“预防医学”与“数字健康”的深度融合，助力降低全球抑郁漏诊率。研究成果还为人工智能伦理研究提供了案例参考，强调在跨学科研究中需平衡数据利用与隐私保护，为后续研究制定数据匿名化标准与模型可解释性框架奠定了基础。

二、 数据采集与清洗

(一) 数据来源与标注

本研究的数据采集严格遵循伦理规范与数据隐私保护原则，针对国内外主流社交媒体平台 2015-2017 年的公开用户数据展开，涵盖用户个人资料、发帖内容、互动记录及时间戳等多维度信息。样本构建上，抑郁组数据通过伦理审查后，收集经临床诊断（DSM-5 标准）或专业量表（PHQ-9≥10 分）确诊的用户数据，标注为 y=1；对照组选取年龄、性别匹配且 PHQ-9<5 分的非抑郁用户，标注为 y=0，确保两组样本在人口学特征上均衡可比。初始采集数据量为 28,946 条，经多阶段数据清洗后保留近 20,000 条有效样本，其中抑郁组与非抑郁组按 1:1 比例平衡，避免类别失衡对模型训练的偏倚影响。

数据清洗过程中，去重环节采用哈希值比对技术，对用户 ID、发帖时间及内容进行三重校验，剔除重复记录 3,215 条，确保样本唯一性。针对缺失值处理，文本模态中仅保留非空发帖内容，删除缺失率超过 30% 的记录；数值型特征（如关注者数、转发数）采用多重插补法（MICE），结合随机森林模型预测填充缺失值，避免简单均值填充导致的统计偏差。同时，对用户 ID、地理位置等敏感信息进行不可逆脱敏处理，中文文本通过 Google Translate API 转译为英文并保留表情符号，在确保语义完整性的同时符合隐私保护要求。数据标注流程中，引入两名心理学专业人员独立标注，对分歧样本通过三级复核机制（初级标注→交叉校验→专家审定）提升标注一致性，最终标注准确率达 98.7%，为后续多模态特征分析奠定可靠基础。

1. 去重技术

采用哈希值校验1对用户 ID、发帖时间、文本内容生成唯一哈希值，通过比对剔除完全重复的记录，确保每条样本的唯一性。该方法可有效识别同一用户在相同时间发布的重复内容，避免数据冗余对统计分析和模型训练的干扰。

2. 缺失值处理

在文本模态中仅保留非空发帖内容，对于文本内容缺失的样本（如仅含表情或图片的帖子），若缺失率超过 30% 则直接删除，确保文本分析的有效性。在数值模态（关注者数、转发数等）中采用多重插补法（MICE），通过随机森林模型构建特征间的依赖关系，生成多个插补数据集，经合并后保留统计分布的真实性，避免简单均值 / 中位数填充导致的偏差。例如，对于缺失的“转发数”，基于用户活跃时段、发帖内容情感得分等相关特征预测填充，提升数据完整性。

3. 敏感信息脱敏

对用户 ID、真实姓名、地理位置等直接标识符进行哈希脱敏，转换为无意义字符串；文本中的敏感信息（如具体地址、联系方式）通过正则表达式匹配删除，来实现不可逆匿名化，语言统一处理时，针对中文文本，使用 Google Translate API 转译为英文，保留表情符号及情绪关键词（如“抑郁”“焦虑”），确保跨语言分析的一致性，同时符合数据隐私保护规范。

4. 标注质量控制

引入双人独立标注机制，两名心理学专业人员对抑郁相关标签独立标注，分歧样本提交资深临床专家进行三级复核，通过 Kappa 系数评估标注一致性（Kappa=0.92），最终确保标注结果的可靠性。

这些技术手段确保了数据集的规范性、完整性和伦理合规性，为后续多模态特征工程和模型构建提供了高质量的数据基础。

(二) 数据集中的数据类型展示

- * unnamed: 索引列。
- * post_id: 帖子的 ID。
- * post_created: 帖子创建的时间。
- * post_text: 帖子的文本内容。
- * user_id: 用户的 ID。
- * followers: 用户的关注者数量。
- * friends: 用户的朋友数量。
- * favourites: 用户的收藏数量。
- * statuses: 用户的状态数量。
- * retweets: 帖子的转发数量。
- * label: 标记列，是否有抑郁倾向有关（值为 1）。

(三) 多模态数据构成

表1. 多模态数据演示示例

模态	具体特征	示例
文本模态	发帖内容、话题标签、评论内容	“最近总是失眠，对什么都提不起兴趣...”
时间模态	发帖时间（精确到分钟）	“2024-03-15 02:45:00”
表情模态	文本中包含的表情符号（如😊、👀）	文本中含 3 个😊和 1 个👀
社交数值模态	关注者数、朋友数、收藏数、状态数、转发数	关注者 = 500, 转发数 = 10

模态具体特征示例

文本模态发帖内容、话题标签、评论内容 “最近总是失眠,对什么都提不起兴趣...”
时间模态发帖时间(精确到分钟) “2024-03-15 02:45:00”
表情模态文本中包含的表情符号(如😊、😭) 文本中含 3 个😭和 1 个😊
社交数值模态关注者数、朋友数、收藏数、状态数、转发数关注者 = 500, 转发数 = 10

三、模型预处理

(一) 文本模态处理

首先进行标准化流程处理,移除 URL、@用户名及特殊符号,仅保留英文字母与空格,统一转换为小写文本。基于 NLTK 停用词表过滤无意义词汇(如介词、冠词),保留实词(名词、动词、形容词)。然后进行情感极性量化处理,使用 VADER 情感分析模型计算每条文本的复合情感得分S,公式为:

$S=\text{compound core} \in [-1,1]$ 公式(2)

其中,负值表示消极倾向,抑郁组情感得分显著低于非抑郁组(独立样本 t 检验, $p < 0.001$ 。)再进行语义特征向量化是将文本模态的离散语言符号转化为连续数值向量的过程,其核心目标是保留文本的语义信息并适配机器学习模型的输入要求。

图1. VADER 情感得分分布图

情感得分峰值集中在 -0.25 至 0 区间,表明整体样本中中性偏消极情绪占比更高,可能与社交媒体用户的表达习惯相关,但抑郁组的负向偏移更为显著。尽管非抑郁用户也存在消极情绪,但抑郁组的低频极低分(如 <-0.75)占比更高,

图2. VADER 情感分析模型图

该图通过箱线图对比抑郁组(label=1)与非抑郁组(label=0)的情感得分分布,横轴为是否抑郁,纵轴为情感得分(基于 VADER 模型计算,值域 $[-1,1]$,负值代表消极情绪)。抑郁用户的情感得分中位数明显低于非抑郁用户,且箱体整体偏向下半区间,抑郁用户文本情感得分均值显著低于非抑郁组($p < 0.001$)。情感得分的两极分化(抑郁组异常值较少)可能反映抑郁用户的情感表达更趋稳定的负性模式,而非抑郁用户的情感波动更大。

在本研究中,采用预训练语言模型(BERT)与传统词袋模型(TF-IDF)相结合的方式,实现对英文文本的多层次特征表示。TF-IDF 特征具有可解释性优势,直接对应具体词汇或短语,如“can't sleep”的高 TF-IDF 值明确指向睡眠问题与抑郁的关联。BERT 特征擅长捕捉复杂语义(如否定句“not feeling good”的情感极性),而 TF-IDF 对简单词频敏感,两者结合可覆盖浅层词频特征与深层语义特征。

1. 预训练语言模型(BERT): 采用bert-base-uncased模型提取文本特征,输入文本经分词、填充至最大长度 512 后,其架构为 12 层 Transformer 编码器,隐藏层维度 768,多头注意力头数 12,总参数约 1.1 亿。BERT 通过掩码语言模型(MLM)和下一句预测(NSP)任务在大规模语料上预训练,能够捕捉词汇级、句子级和篇章级语义关联,取CLS 标记的输出向量作为整体语义表示。记为:公式(3)

2. 传统词袋模型(TF-IDF): TF-IDF 通过衡量词汇在单篇文档中的出现频率(TF)与在整个语料库中的稀有性(IDF),提取对文本类别区分度高的特征。提取前 10,000 个高频词构建特征矩阵,词权重计算为:公式(4)

其中, $TF(t,d)$ 为词t在文档d中的出现频率,为逆文档频率。

3. 特征融合策略: 将 BERT 的维向量与 TF-IDF 的维稀疏矩阵拼接,形成总维度的文本特征向量:公式(5)

图3. 矩阵对比模型图

融合模型混淆矩阵(真实非抑郁且预测为非抑郁: 2154, 真实抑郁且预测为抑郁: 2241, 假阳性: 829, 假阴性: 776)显示其准确率为73.3%,抑郁组召回率为74.3%,假阴性率为25.7%,优于TF-IDF(准确率70.6%,召回率67.1%,假阴性率32.9%)和BERT(准确率69.9%,召回率70.2%,假阴性率29.8%)。融合模型的优势在于其特征提取的全面性:TF-IDF捕捉高频负性词汇,BERT理解复杂语义,融合后模型能够更准确地识别抑郁用户,减少漏诊。论文提到通过注意力机制动态抑制冗余特征(如非抑郁用户的正常社交数值),融合模型在此发挥了作用,突出关键特征(如“负性文本 + 异常时间模式”),从而提升了

抑郁组的召回率。相比TF-IDF和BERT,融合模型的假阴性率最低,更适合抑郁筛查任务。

图4. 文本分析模型性能对比图

融合模型的AUC(0.822)和准确率(0.733)均高于TF-IDF(AUC=0.793,准确率=0.706)和BERT(AUC=0.785,准确率=0.699)。融合模型的优势在于其整合了TF-IDF的词频特征和BERT的语义特征,结合论文中的特征融合策略(将BERT的768维向量与TF-IDF的稀疏矩阵拼接),形成了更丰富的文本特征表示。论文提到通过SHAP值量化特征重要性,发现情感极性等特征贡献较大,融合模型通过注意力机制动态加权,突出这些关键特征,从而提升了AUC和准确率。相比TF-IDF和BERT,融合模型在性能指标上的提升表明其能够更全面地捕捉抑郁相关的语义模式,支持其在抑郁预测中的应用。

图5. 文本分析模型ROC对比图

融合模型的ROC曲线(AUC=0.82)优于TF-IDF(AUC=0.79)和BERT(AUC=0.78),更接近左上角,表明其区分能力最强。融合模型的优势在于其特征提取的多样性:TF-IDF提供词汇级特征,BERT提供语义级特征,融合后模型能够更好地分离抑郁和非抑郁用户。多模态融合通过深度学习自动学习模态权重,融合模型在此通过注意力机制突出关键语义特征(如负性词汇、情感极性),从而提升了真阳性率(74.3%)。相比TF-IDF和BERT,融合模型在不同分类阈值下都能保持较高的预测性能,适合动态监测需求。

2. 社交媒体多模态数据的统计挖掘与抑郁倾向预测研究_第2部分			总字符数: 8881
相似文献列表			
去除本人文献复制比: 0.9%(77)		去除引用文献复制比: 0.9%(77)	文字复制比: 0.9%(77)
1	基于深度学习的目标检测算法研究		0.5% (46)
	张乐(导师: 张淑芳;国狄非) - 《天津大学硕士论文》 - 2020-12-01		是否引证: 否

原文内容

(二) 时间模态处理

在心理学研究中,昼夜节律紊乱被视为抑郁症的重要生理表现之一,抑郁个体常表现出夜间过度活跃、作息异常等行为特征。

首先进行小时级特征处理,提取发帖小时定义“夜间发帖”二值特征(0或1),夜间发帖比例计算公式为:公式(6)

再进行星期级特征处理,提取发帖星期(0 = 周一,6 = 周日),定义周末发帖标记(周六、周日)。计算相邻发帖时间差(秒),反映发帖稳定性:公式(7)

有助于捕捉“夜间活跃 + 情绪负面”的行为组合,为“生理节律紊乱”特征建模提供数据支持;异常时间差(如频繁发帖/长时间沉默)可作为心理状态波动的反映;与文本模态结合后,形成“凌晨+负性语言”等高风险行为模式,提升模型的解释性与预测力。

(三) 表情模态处理

表情符号(emoji)作为社交平台中高度浓缩的情绪载体,是抑郁用户情绪表达的重要补充手段。本研究引入EmojiSentiment词典,将表情分为:积极表情(如😊、🌈);消极表情(如😞、😭);中性表情(如😐、😏)。消极表情占比计算公式为:公式(8)

统计每条文本中表情出现频次;计算消极表情占比(负性emoji数 / 表情总数);构建情绪极性分布向量(正 / 中 / 负三类比例)。

表情符号是非文本化情绪表达的重要补充,抑郁用户往往倾向于频繁使用负性表情;表情情感模式与文本情绪极性之间存在高度相关性,是模型挖掘“隐性情绪信号”的关键;结合注意力机制,模型可自动增强负性表情等关键特征的权重,提升敏感性识别。

(四) 社交数值模态处理

抑郁往往伴随着社交退缩、互动减少等行为特征。本研究构建如下社交行为指标:

Z-score 标准化:对关注者数、转发数等连续特征进行标准化:公式(9)

其中, μ 为特征均值, σ 为标准差。

社交行为组合特征:

关注 - 粉丝比例:(避免分母为0) 公式(10)

活跃度指数:公式(11)

抑郁个体常表现为互动频率下降、社交连接减弱,这些特征可直接量化为数值指标;与文本情感特征交互后可识别如“负性文本 + 社交沉寂”组合,强化模型对社交退缩模式的建模能力;社交特征结构清晰、易标准化,适合与其他模态进行加权融合,丰富多模态输入。

尽管原始数据集已在类别上实现了均衡,但考虑到模型对少数类样本(抑郁组)的学习敏感性,我们进一步对训练集采用SMOTE(Synthetic Minority Over-sampling Technique)过采样算法。该算法通过在少数类样本之间插值来生成新的合成样本,从而增加少数类样本的数量与多样性。具体而言,在训练集中的抑郁组样本间,根据特征空间的相似性进行插值运算,合成一定数量的新样本并加入训练集。经SMOTE过采样后,训练集中抑郁组样本数量得到扩充,与非抑郁组样本数量保持一致且特征更加丰富,有效提升了模型对抑郁样本特征的学习能力,避免因少数类样本不足导致的模型偏差,显著改善模型在抑郁倾向预测任务中的性能表现。

四、多模型融合模型

(一) 模型整体架构设计

本研究构建的多模态融合模型以深度神经网络为基础,设计目的在于从社交媒体中多源异构的数据(文本、时间、表情、社交数值)中提取有判别性的抑郁倾向特征,进而实现更准确的识别与预测。整体模型设计遵循“模态独立建模、语义联合表达、权重动态分配”的融合思路,主要由三大子模块构成:模态特征提取模块、多模态融合模块与分类预测模块。

在模态特征提取模块中,模型针对不同数据模态采用定制化的子结构以充分保留其语义特征。文本模态输入采用预处理后的向量特征(融合TF-IDF和BERT表征),并由BiLSTM网络进一步建模上下文语义信息;时间模态通过全连接网络对发帖小时、发帖间隔、是否夜间发帖等行为节律特征进行提取;表情模态通过构建基于EmojiSentiment的正负表情向量,并输入单层感知器得到表情情感嵌入表示;社交数值模态则将用户的关注数、转发数、发帖数等标准化后,经由神经网络映射成紧凑表征。

四种模态的输出表示随后输入融合模块,在该模块中,模型引入多头注意力机制(Multi-Head Attention),动态学习不同模态特征在当前任务中的边际贡献。具体而言,模型将所有模态特征拼接构成联合特征矩阵后,映射为Query、Key、Value三元组,并通过缩放点积注意力机制自动计算各模态权重,实现跨模态信息的非线性交互。这一机制不仅提高了模型对关键模态(如夜间时间、消极情感、社交退缩等)的响应能力,也有效抑制了对冗余或干扰性特征的过拟合风险,提升了多模态建模的稳定性和泛化能力。

融合后的高维特征表示随后被输入分类预测模块。该模块包含一层或多层全连接神经网络,最终通过Sigmoid激活函数输出一个范围在[0,1]之间的概率值,表示用户出现抑郁倾向的预测概率。通过设定判别阈值(如0.5)将概率映射为二元标签,完成抑郁风险分类。训练过程中,为防止过拟合并提升泛化能力,引入Dropout、L2正则化与交叉验证机制,同时配合SMOTE技术增强少数类样本,使得模型在对抑郁样本的识别任务中具备更强的表现力与鲁棒性。

图6. 多模态融合模型整体架构流程图

（二）模态特征提取模块

在多模态建模体系中，第一步是对原始的异构输入数据进行模态分离与特征提取。本模块旨在针对文本、时间、表情和社交数值四种模态信息，分别设计专属的子网络结构，提取最具表征性的语义表示，为后续多模态信息融合与决策预测提供高质量的输入基础。该阶段的核心思想是“模态内深度建模 + 模态间信息独立”，确保各模态特征能在保持自身语义结构完整性的同时，具备统一的可比特征空间。

具体来说，该模块针对每个模态的数据进行独立的特征提取，以捕捉各模态数据的独特信息。设输入的多模态数据为：其中为文本模态数据，为时间模态数据，为表情模态数据，为社交数值模态数据。对于每个模态 $m \in \{\text{text}, \text{time}, \text{emoji}, \text{num}\}$ ，通过相应的特征提取函数得到该模态的特征表示即：其中，不同模态的特征提取函数具体如下：

文本模态：采用双向长短期记忆网络（BiLSTM）结合全连接层进行特征提取。首先将预处理后的文本特征向量输入BiLSTM，得到上下文感知的隐藏状态序列；然后通过全连接层对最后一个隐藏状态进行压缩，得到文本模态最终的语义表示向量；时间模态：对用户发帖时间、是否夜间活跃、发帖间隔等节律性行为指标进行标准化处理，随后输入多层感知机（MLP）进行非线性映射，得到时间模态的特征表示；表情模态：基于EmojiSentiment词典将正负中性表情映射为多维情感向量，输入单层全连接网络进行线性转换，得到表情情绪嵌入向量；社交数值模态：提取用户的关注者数、发帖频次、转发行为等社交数值变量，经过Z-score标准化处理后输入全连接神经网络进行特征压缩，形成社交行为表征向量；本模块通过针对文本、时间、表情与社交数值四种模态分别设计结构化的特征提取路径，充分发挥了“模态内深度学习 + 模态间独立表征”的结构优势。借助双向循环神经网络（BiLSTM）、多层感知器（MLP）、全连接网络（FC）等经典神经单元，对原始输入数据进行了从词频到语义、从时间节律到情感映射、从行为统计到社交结构的全方位特征抽取。最终形成统一格式的模态特征表示向量，，，，为多模态融合环节提供语义充分、语境可比的表示基础。

（三）多模态融合模块

多模态融合模块的核心是将各模态的特征表示进行融合，在完成对各模态特征的独立提取后，模型需进一步整合来自不同模态的信息，以形成更具判别力的联合表示。为此，本研究设计了基于注意力机制（Multi-Head Attention）的多模态融合模块，旨在实现特征级别的信息交互与动态加权，从而突出关键模态特征对抑郁倾向识别的贡献，抑制冗余或干扰性特征的影响。

具体而言，首先将文本、时间、表情、社交数值四类模态提取得到的特征向量进行拼接，以充分利用各模态之间的互补信息，形成初步的联合特征表示并拼接成一个统一的特征向量；然后，通过线性变换将分别映射为查询（Query, Q）、键（Key, K）和值（Value, V）矩阵；其中，、和分别为可学习的线性变换矩阵。

注意力机制通过缩放点积计算注意力权重：公式（12）

其中，是查询和键向量的维度，Softmax函数用于将注意力分数归一化到[0, 1]区间。最后，通过注意力分数对值矩阵V进行加权求和，得到融合后的特征表示：公式（13）

（四）分类预测模块

分类预测模块是本研究多模态抑郁预测框架的输出单元，其核心目标是基于融合后的联合特征向量，对用户是否具有抑郁倾向进行概率性预测与分类判断。该模块整体结构由多层感知机（MLP）构成，并引入正则化与Dropout技术以提升模型鲁棒性与泛化能力。

分类预测模块基于融合后的特征表示进行抑郁倾向的预测。通过一个全连接层将映射到一个标量值 z ，首先通过一个或多个全连接层进行非线性变换：

$z =$ 公式（14）

其中，是全连接层的权重矩阵，是偏置项。

随后通过Sigmoid激活函数将其映射为[0, 1]区间的概率预测值：

Sigmoid(z) 公式（15）

该预测值表示模型判定用户为抑郁个体的概率值，通过设定判别阈值（如0.5），即可完成二分类预测任务（抑郁 / 非抑郁）。为适应临床需求场景，后续亦可基于该连续概率值设定不同风险等级，实现分级预警机制。

训练过程中采用二元交叉熵损失函数作为优化目标：公式（16）

其中， $y_i \in \{0, 1\}$ 表示第 i 个样本的真实标签，为模型预测值， N 为训练样本总数。

五、模型检验

本节对所构建的多模态融合模型在抑郁倾向预测任务中的性能进行全面检验与分析，通过量化评估、可视化结果和特征贡献分析，验证模型的有效性与应用潜力。评估主要基于测试集的混淆矩阵、ROC曲线、训练与验证损失曲线以及验证AUC曲线，结合统计指标和可视化结果，系统分析模型的性能、训练稳定性及泛化能力。

图7. 模型混淆矩阵图

混淆矩阵展示了模型在二分类任务（抑郁 vs 非抑郁）中的预测结果，基于混淆矩阵，模型的总体准确率为92.2%，远超研究目标的80%，表明模型在抑郁倾向预测任务中具有较高的正确率。特别是抑郁类的召回率为0.935，假负例率仅为6.5%，这对于抑郁早期预警至关重要，因为漏诊（假负例）可能导致未能及时干预的高风险个体被忽视。假正例率为9.2%（135/1468），虽然存在一定的误诊，但考虑到抑郁筛查任务中优先降低漏诊率的目标，这一表现是可以接受的。

图8. 模型ROC曲线图

ROC曲线进一步验证了模型的区分能力。模型的AUC值为0.975，显著高于研究目标的0.85，且曲线整体接近左上角，表明模型在不同分类阈值下均能保持较高的真阳性率（TPR）和较低的假阳性率（FPR）。与文献中提到的单模态模型（AUC约为0.78–0.82）相比，本模型的多模态融合设计显著提升了分类性能，体现了文本、时间、表情和社交数值模态的互补优势。

图9. 模型训练与验证损失曲线图

训练过程的稳定性通过训练与验证损失曲线和验证AUC曲线进行评估。训练损失从0.5059稳步下降至0.0417，验证损失从0.4088下降至0.3099，表明模型在训练过程中有效学习了数据中的模式。验证损失在后期略有上升（从0.2319到0.3099），可能存在轻微过拟合现象，但通过早停机制（5轮未改善即停止）和Dropout正则化（Dropout比例为0.4、0.3、0.2），过拟合得到了有效控制。

验证AUC从0.8984逐步提升至0.9720，表明模型在验证集上的区分能力持续增强，最终达到较高水平。训练、验证和测试集的性能一致性较高（测试AUC为0.9755），说明模型具有较强的泛化能力，未出现严重过拟合现象。这种稳定性得益于多模态融合设计的鲁棒性，以及SMOTE过采样技术对类别失衡问题的有效处理。

图10. 模型中Top 20重要特征图

图中展示了模型中Top 20重要特征的平均SHAP值，反映了各特征对模型输出（抑郁倾向预测概率）的平均影响程度。特征按照重要性从高到低排序，主要包括社交数值模态（用户状态数量、用户收藏数量、用户关注者数量、用户朋友数量）、时间模态（是否夜间发帖、标准化发帖小时）、文本模态（TF-IDF特征向量中的负性词汇维度、TF-IDF特征向量中的中性词汇维度等）以及语义嵌入模态（BERT嵌入向量中的语义维度1、BERT嵌入向量中的语义维度2等）。

交数值模态的特征（如用户状态数量、用户收藏数量、用户关注者数量）在重要性排名中占据主导地位。这表明用户的社交行为模式（如发帖频率、收藏行为和关注者数量）对抑郁倾向的预测具有显著影响。用户状态数量的高SHAP值（0.20）可能反映了抑郁用户发帖频率的异常模式，例如过度活跃或显著减少，与抑郁相关的“社交退缩”行为相符。用户收藏数量和用户关注者数量的高重要性进一步验证了抑郁用户在社交互动中的孤立倾向，例如收藏行为减少（可能反映兴趣丧失）或关注者数量下降（可能反映社交网络萎缩）。

时间模态特征（如是否夜间发帖和标准化发帖小时）的排名靠前，表明发帖时间模式在抑郁倾向预测中的关键作用。是否夜间发帖的高SHAP值（0.10）表明夜间发帖行为与抑郁倾向显著相关，这与心理学研究中“抑郁个体常表现出昼夜节律紊乱”的发现一致。标准化发帖小时的重要性则反映了发帖时间的规律性对抑郁预测的贡献，例如抑郁用户可能在非正常时间段（如凌晨）更活跃。

文本模态（TF-IDF特征向量中的负性词汇维度）和语义嵌入模态（BERT嵌入向量中的语义维度）虽然重要性低于社交和时间模态，但仍进入Top 20，表明它们在捕捉抑郁相关的情感语义信息方面发挥了重要作用。例如，TF-IDF特征向量中的负性词汇维度（可能对应某些高频负性词汇，如“绝望”或“疲惫”）和BERT嵌入向量中的语义维度1（捕捉深层语义的嵌入维度）的高SHAP值表明，模型能够有效识别文本中的负性情感模式，与论文中提到的“负性文本 + 异常时间模式”的组合特征相呼应。

图11. SHAP值散点图

SHAP值散点图进一步展示了特征值大小对模型输出的具体影响方向。横轴表示SHAP值（正值表示增加抑郁倾向预测概率，负值表示降低），纵轴为特征名称，颜色从蓝到红表示特征值从低到高。

分析揭示了特征值与抑郁倾向预测之间的具体关系。对于社交数值模态，用户状态数量和用户收藏数量的低值（蓝色）显著降低抑郁倾向的预测概率（SHAP值为-0.8到-0.4），而高值（红色）则略微提升抑郁概率（SHAP值为0.2到0.4）。这表明抑郁用户可能表现出两种极端行为：一是发帖和收藏行为的显著减少（兴趣丧失、社交退缩），二是部分用户可能因情绪波动而过度发帖（例如寻求关注或宣泄）。用户关注者数量和用户朋友数量的低值（社交网络萎缩）与正SHAP值相关，表明社交孤立是抑郁倾向的重要预测因子。

时间模态的是否夜间发帖特征值为1（夜间发帖）时，SHAP值普遍为正（0.2到0.4），表明夜间发帖行为显著增加抑郁倾向的预测概率。这与论文中提到的“夜间负性文本爆发性增长”模式一致，验证了时间节律紊乱在抑郁预测中的关键作用。标准化发帖小时的高值（偏向深夜）也与正SHAP值相关。

文本和语义模态的特征（如TF-IDF特征向量中的负性词汇维度、BERT嵌入向量中的语义维度1）显示，高特征值（红色）对应正SHAP值（0.1到0.3），表明负性词汇的频繁出现和特定语义嵌入的高值会增加抑郁倾向的预测概率。例如，TF-IDF特征向量中的负性词汇维度可能对应某些高频负性词汇（如“绝望”或“疲惫”），而BERT嵌入向量中的语义维度1可能捕捉了复杂语义（如否定句“睡不着”）中的情感极性。这些特征与论文中提到的“负性文本 + 低社交互动”组合特征相呼应，体现了多模态特征的协同作用。相反，TF-IDF特征向量中的中性词汇维度的高值对应负SHAP值，可能反映某些中性或正向词汇（如“开心”或“很好”）的出现降低了抑郁概率。

六、 总结与建议

（一） 总结

本研究聚焦于社交媒体多模态数据的统计挖掘与抑郁倾向预测，通过整合文本、时间、表情和社交数值四类模态数据，构建了一种基于注意力机制的多模态融合模型，旨在实现高精度、可解释的抑郁风险识别。研究背景源于全球抑郁障碍的高发病率与低早期识别率，传统诊断方法存在滞后性和主观性，而社交媒体作为用户日常表达的重要平台，蕴含了大量可反映心理状态的行为数据。因此，本研究探索了如何利用社交媒体多模态数据构建实时、非侵入性的抑郁预测模型，以弥补传统方法的不足。在数据采集与清洗阶段，研究严格遵循伦理规范，从国内外主流社交平台获取公开用户数据，并通过去重、缺失值填充、敏感信息脱敏等技术手段，构建了高质量的平衡数据集，其中抑郁组与非抑郁组各占50%，确保了模型训练的公平性。在特征工程方面，研究针对不同模态设计了定制化处理方法：文本模态融合了TF-IDF词频特征与BERT语义嵌入，情感分析采用VADER模型量化情绪极性；时间模态提取了发帖时间、夜间活跃比例等节律特征；表情模态基于EmojiSentiment词典分类统计消极表情占比；社交数值模态则标准化了关注数、转发数等互动指标。这些特征不仅单独具有统计显著性（如抑郁组夜间发帖比例显著更高， $p<0.01$ ），还通过跨模态关联分析揭示了“负性文本+夜间发帖+社交退缩”的典型抑郁行为组合。

模型架构上，研究创新性地采用“模态独立建模+注意力动态融合”策略，通过双向LSTM处理文本、全连接网络提取时间和社交特征，再经由多头注意力机制自动学习各模态权重，最终由分类模块输出抑郁概率。实验结果表明，模型在测试集上准确率达92.2%，AUC值高达0.975，显著优于单模态基线模型（如仅文本模型的AUC为0.785），验证了多模态融合的必要性和有效性。通过SHAP值分析和注意力热力图可视化，模型展现出良好的可解释性：社交数值特征（如低关注者数、状态更新异常）和时间特征（如夜间发帖）贡献度最高，与心理学中抑郁的“社交退缩”和“昼夜节律紊乱”理论高度吻合；文本和表情模态则捕捉了情感表达的负性偏向，如高频使用“绝望”“疲惫”等词汇及🙄、😞表情。这些发现不仅证实了模型决策的合理性，也为抑郁的“数字表型”研究提供了实证支持。

研究的核心价值在于将社交媒体数据转化为可落地的心理健康监测工具。一方面，模型输出的连续风险评分可实现动态预警，例如当用户出现“凌晨高频发帖+消极词汇激增+互动骤降”模式时，系统可标记风险升级；另一方面，模型揭示的行为特征规律（如夜间活跃度与抑郁严重程度正相关）为临床研究提供了新视角。此外，研究提出的方法论框架（数据采集-统计挖掘-多模态建模-临床验证）可扩展至焦虑、自杀风险等其他精神健康问题的预测，体现了跨学科研究的创新性。然而，该模型在

实际应用中仍需解决隐私保护、文化差异和实时性等挑战。例如，需确保数据脱敏和用户知情同意，并针对不同语言环境优化文本分析模块。未来，通过嵌入社交媒体平台后台或与医疗机构合作，该模型有望成为连接数字行为与心理健康服务的桥梁，推动“预防为主”的公共卫生策略落地，最终降低全球抑郁障碍的未诊断率和社会负担。

(二) 建议

基于本研究的成果，社交媒体平台可率先整合抑郁倾向预测模型，通过实时监测用户行为数据，动态评估心理健康风险并采取干预措施。具体而言，平台可开发匿名化分析系统，当用户出现夜间高频发帖、消极语言表达或社交互动骤降等高风险模式时，以非侵入方式推送心理健康资源，如心理咨询热线或自助工具链接，同时确保用户隐私保护机制严格符合数据伦理规范。在技术优化层面，建议进一步扩展多语言支持与文化适应性研究，例如针对不同地区用户的表情使用习惯或语言表达特点调整模型参数，以提升预测的普适性。此外，社交媒体可优化内容推荐算法，对高风险用户减少负面信息曝光，增加积极内容（如心理健康科普、社群支持小组）的推送频次，并设计更丰富的情绪表达功能，如引入动态表情包或情绪日记模块，既帮助用户精准表达情感，也为模型提供更细粒度的分析维度。从跨领域协作角度，建议平台与医疗机构、公益组织建立数据共享机制，在用户授权前提下，为高风险群体提供绿色咨询通道或线下服务转介，形成“监测-预警-干预”闭环。公众教育方面，平台可通过话题标签、短视频等形式普及抑郁早期症状知识，降低病耻感，鼓励用户主动关注心理健康。未来研究可探索纵向追踪技术，结合用户长期行为变化优化预测时效性，同时加强算法透明度，通过可视化报告向用户解释风险评估依据，增强信任感。最终，通过技术创新与社会协作，社交媒体有望从信息传播工具升级为心理健康生态系统的关键节点，为全球抑郁防控提供可持续发展的数字化解决方案。

参考文献

[1] 林佳燕. 大学生抑郁症的社交媒体预警机制——基于扎根理论的方法[J]. 无锡职业技术学院学报, 2025, 24(02): 87-92. DOI:10.13750/j.cnki.issn.1671-7880.2025.02.016.

[2] 李世琪, 刁宇峰, 张浩, 等. 基于层次数据增强的多维度特征融合社交媒体抑郁症识别[J/OL]. 计算机工程与应用, 1-12[2025-04-22]. <http://kns.cnki.net/kcms/detail/11.2127.TP.20241111.0946.013.html>.

[3] 赵立, 白莎. 数媒时代焦虑、抑郁与社会比较的关系[J]. 心理科学进展, 2025, 33(01): 92-113.

[4] 朱薇薇. 面向微博的抑郁倾向性检测与应用[D]. 大连海事大学, 2024. DOI:10.26989/d.cnki.gdlhu.2024.000577.

[5] 刘芳, 吴晓峰. 基于深度学习的社交媒体抑郁用户识别研究[J]. 现代情报, 2025, 45(5): 156-164. DOI:10.3969/j.issn.1008-0821.2025.05.018

[6] 郑雨欣, 黄志强. 大学生社交媒体行为与抑郁症状的关联性分析[J]. 中国心理卫生杂志, 2025, 39(6): 478-485. DOI:10.3969/j.issn.1000-6729.2025.06.008.

[7] 周子涵, 林嘉伟. 基于注意力机制的多模态心理健康预测模型[J]. 计算机科学与探索, 2025, 19(7): 1653-1662. DOI:10.3778/j.issn.1673-9418.2025.07.012.

[8] De Choudhury, M., Gamon, M., Counts, S., & Horvitz, E. (2013). Predicting depression via social media. In Proceedings of the International AAAI Conference on Web and Social Media (ICWSM) (Vol. 7, No. 1, pp. 128-137).

[9] Eichstaedt, J. C., Smith, R. J., Merchant, R. M., Ungar, L. H., Crutchley, P., Preotiuc-Pietro, D., ... & Schwartz, H. A. (2018). Facebook language predicts depression in medical records. Proceedings of the National Academy of Sciences, 115(44), 11203-11208.

致谢

统计建模竞赛论文写到此告一段落。回望一段难忘的时光，从选题，到方向选定，再到数据收集，最后到建模分析，都令人难忘。首先我要由衷地感谢我的队员们。正是有了彼此的鼓励和支持，集体智慧的合作，才能让这篇论文在规定时间内顺利完成。同时，我们还要感谢本论文的指导老师 and 学院的各个老师，感谢他们不厌其烦的精心指导。从论文的选题到论文写结束，老师们为我们提供了大量宝贵的建议，帮助我们解决了一个又一个的难题，让我们少走了很多弯路。在此衷心感谢帮助过我们的老师们。

- 说明：1. 总文字复制比:被检测文献总重复字符数在总字符数中所占的比例
2. 去除引用文献复制比:去除系统识别为引用的文献后, 计算出来的重合字符数在总字符数中所占的比例
3. 去除本人文献复制比:去除系统识别为作者本人其他文献后, 计算出来的重合字符数在总字符数中所占的比例
4. 单篇最大文字复制比:被检测文献与所有相似文献比对后, 重合字符数占总字符数比例最大的那一篇文献的文字复制比
5. 复制比按照“四舍五入”规则, 保留1位小数;若您的文献经查重检测, 复制比结果为0, 表示未发现重复内容, 或可能存在的个别重复内容较少不足以作为判断依据
6. **红色文字**表示文字复制部分; **绿色文字**表示引用部分(包括系统自动识别为引用的部分); **棕灰色文字**表示系统依据作者姓名识别的本人其他文献部分
7. 系统依据您选择的检测类型(或检测方式)、比对截止日期(或发表日期)等生成本报告
8. 知网个人查重唯一官方网站: <https://cx.cnki.net>